

Detección y prevención de acciones maliciosas en agentes de inteligencia artificial

Autor:
Esp. Ing. Florencia Priscilla Vela

Director:
Ms. Abraham Adolfo Rodriguez Zepeda (FIUBA)

Esta planificación fue realizada en el curso de Gestión de proyectos entre el 19 de octubre de 2026 y el 7 de diciembre de 2026.

Índice

1. Descripción técnica-conceptual del proyecto a realizar **5**
1.1 Contexto y motivación 5
1.2 Descripción funcional y técnica 5
1.3 Estado del arte 6
1.4 Grado de innovación 7
1.5 Conjunto de datos y estrategia de experimentación 7

2. Identificación y análisis de los interesados **7**

3. Propósito del proyecto **8**

4. Alcance del proyecto **8**

5. Supuestos del proyecto **9**

6. Requerimientos **9**

7. Historias de usuarios (*Product backlog*) **11**

8. Entregables principales del proyecto **14**

9. Desglose del trabajo en tareas **14**

10. Diagrama de Activity On Node **16**

11. Diagrama de Gantt **17**

12. Presupuesto detallado del proyecto **19**

13. Gestión de riesgos **21**

14. Gestión de la calidad **22**

15. Procesos de cierre **24**

Registros de cambios

Revisión	Detalles de los cambios realizados	Fecha
0	Creación del documento	19 de octubre de 2026
1	Se completa hasta el punto 6 inclusive	29 de octubre de 2026
2	Se realizan las correcciones recomendadas y se completa hasta el punto 9 inclusive	6 de noviembre de 2026

Acta de constitución del proyecto

Buenos Aires, 19 de octubre de 2026

Por medio de la presente se acuerda con el Esp. Ing. Florencia Priscilla Vela que su Trabajo Final de la Maestría en Inteligencia Artificial se titulará "Detección y prevención de acciones maliciosas en agentes de inteligencia artificial" y consistirá en el desarrollo de un sistema que evalúa cada acción propuesta por un agente de IA antes de ejecutarla y decide si permitirla, revisarla o bloquearla según su riesgo. El trabajo tendrá un presupuesto preliminar estimado de 600 horas y un costo estimado de USD 9.490, con fecha de inicio el 19 de octubre de 2026 y fecha de presentación pública en noviembre de 2027.

Se adjunta a esta acta la planificación inicial.

Dr. Ing. Ariel Lutenberg
Director posgrado FIUBA

Ms. Abraham Adolfo Rodriguez Zepeda
Director del Trabajo Final

1. Descripción técnica-conceptual del proyecto a realizar

1.1. Contexto y motivación

Los modelos de lenguaje de gran escala (en inglés, *Large Language Models* o LLM) se difundieron como sistemas conversacionales capaces de procesar y generar texto. A partir de estas capacidades se desarrollaron los agentes de inteligencia artificial (IA), que incorporan la capacidad de planificar y ejecutar tareas mediante herramientas. Así, además de responder consultas, un agente puede leer y modificar archivos, ejecutar comandos, enviar correos o utilizar servicios externos. Esta capacidad de acción amplía sus posibilidades de aplicación, pero también les permite acceder a recursos sensibles y genera nuevos riesgos de seguridad.

Uno de estos riesgos se presenta cuando un agente consulta una página web o un documento que contiene instrucciones maliciosas. El agente puede interpretar esas instrucciones como parte de la solicitud original y actuar en consecuencia. Este tipo de ataque, conocido como *prompt injection* o inyección de instrucciones, podría llevarlo a divulgar información sensible, enviar datos a destinos no autorizados, modificar o borrar recursos sin permiso, ejecutar código no aprobado o intentar ampliar sus privilegios. El momento de la detección es fundamental, ya que, si el desvío se identifica después de ejecutar la acción, el daño puede ser difícil o imposible de revertir. Por eso, resulta necesario contar con controles que evalúen las acciones antes de que se ejecuten.

1.2. Descripción funcional y técnica

En este contexto, el proyecto propone desarrollar un componente de control que actúe como intermediario entre el agente y sus herramientas. Su función es evaluar cada acción propuesta y decidir si corresponde permitirla, enviarla a revisión o bloquearla antes de su ejecución. Se trata de una iniciativa académica individual en el marco del Trabajo Final de la Maestría en Inteligencia Artificial. El proyecto está dirigido a personas u organizaciones que utilizan agentes para trabajar con datos, archivos o servicios y necesitan delegar tareas sin exponer recursos sensibles. Para estos usuarios, resultan especialmente relevantes la preservación de la privacidad y la precisión de las alertas, de manera que el sistema detecte acciones riesgosas sin interrumpir innecesariamente las tareas legítimas.

Para tomar cada decisión, el sistema considera tres fuentes de información: los permisos del agente, la herramienta que pretende utilizar junto con sus argumentos y el contexto reciente de la sesión. La evaluación combina el grado en que una acción se aparta del comportamiento esperado con su coherencia respecto del objetivo de la tarea y los permisos otorgados. Se busca que el control funcione en tiempo real, con baja latencia, y que pueda ejecutarse de manera local y liviana en la máquina del usuario para preservar la privacidad.

El funcionamiento del componente de control se presenta en la figura 1. Cuando el agente propone una acción, el componente de control aplica primero un conjunto de reglas explícitas de permisos independientes del modelo de IA. Por ejemplo, una regla puede impedir que un agente con determinado rol lea un archivo de credenciales. Si estas reglas no son suficientes para resolver la decisión, interviene un modelo de riesgo que evalúa la acción considerando el contexto de la sesión. La decisión final integra ambos mecanismos: solo las acciones clasificadas como permitidas llegan al ejecutor; las que requieren revisión quedan pendientes y las bloqueadas no se ejecutan. Las restricciones establecidas por las reglas mantienen su validez independientemente de la puntuación del modelo, de modo que este no puede anular una prohibición explícita.

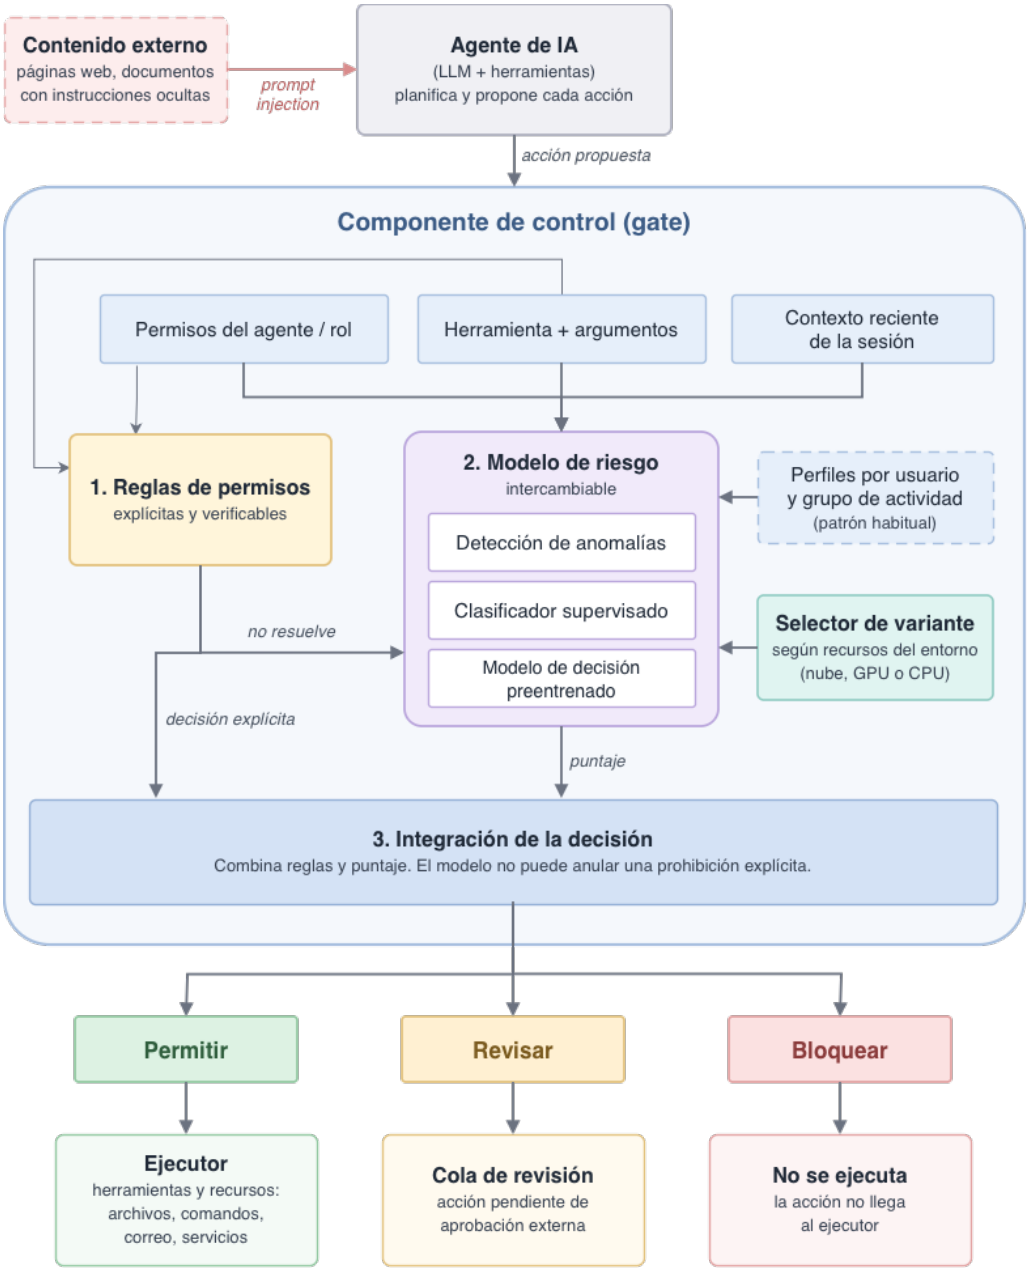


Figura 1. Diagrama en bloques del sistema.

1.3. Estado del arte

En cuanto al estado del arte, se identifican distintas líneas de trabajo relacionadas con el problema. Una de ellas comprende modelos de protección como Llama Guard, ShieldGemma y Granite Guardian, que permiten detectar riesgos en las entradas y respuestas de los modelos de lenguaje. Otra incluye modelos orientados a producir decisiones estructuradas a partir de un contexto y una pregunta, como Jev y Laya. Estos modelos pueden devolver una categoría, una puntuación o una probabilidad, por lo que constituyen alternativas para explorar en la evaluación de acciones. También existen mecanismos de control sobre el uso de herramientas, como Invariant Guardrails y Progent, y sistemas de protección para agentes, como LlamaFirewall. A estas líneas se suman las técnicas de detección de anomalías de comportamiento, que permiten identificar desviaciones respecto de patrones habituales.

1.4. Grado de innovación

La principal innovación del proyecto está en controlar cada acción en el instante previo a su ejecución, antes de que un desvío pueda provocar un daño difícil de revertir, en lugar de detectarlo una vez producido. A su vez, las reglas de permisos verificables operan con prioridad sobre el modelo de riesgo, de manera que una prohibición explícita nunca puede ser anulada por su puntuación.

Además, se busca que el sistema pueda ejecutarse en equipos con recursos computacionales limitados. Para ello se explorarán variantes cuantizadas, que reducen los requisitos de memoria y facilitan el uso de modelos en máquinas de capacidad limitada. La propuesta combina reglas verificables con una evaluación contextual del riesgo, y su utilidad deberá analizarse en comparación con los enfoques existentes, considerando tanto la detección de acciones riesgosas como la latencia y el consumo de recursos.

1.5. Conjunto de datos y estrategia de experimentación

Una de las etapas más importantes será definir el conjunto de datos sobre el cual se realizarán las pruebas, ya que caracterizar un comportamiento como malicioso constituye un problema complejo. Una misma acción puede ser legítima o riesgosa según el objetivo de la tarea, los permisos otorgados, los recursos involucrados y el contexto en el que se propone. Además, una acción poco habitual no necesariamente es maliciosa, y una acción frecuente puede resultar perjudicial si se realiza sin autorización.

Por este motivo, la construcción del conjunto de datos requerirá establecer criterios claros para distinguir acciones permitidas, acciones que requieren revisión y acciones que deben bloquearse. Se prevé considerar datos públicos y ejemplos sintéticos que representen tanto tareas legítimas como intentos de desvío y situaciones ambiguas. Sobre esta base se compararán detectores de anomalías, clasificadores supervisados y modelos de decisión preentrenados, con el objetivo de identificar qué enfoques ofrecen el equilibrio más adecuado entre detección de riesgos, precisión de las alertas y requisitos de ejecución.

2. Identificación y análisis de los interesados

En la tabla 1 se identifican los interesados del proyecto. Al tratarse de un Trabajo Final de carácter académico e individual, varios roles habituales en proyectos mayores (auspiciante, impulsor, colaboradores, equipo, opositores) no aplican y se omiten.

Cuadro 1. Identificación de los interesados.

Rol	Nombre y Apellido	Organización	Puesto
Responsable	Esp. Ing. Florencia Priscilla Vela	FIUBA	Alumna
Orientador	Ms. Abraham Adolfo Rodriguez Zepeda	FIUBA	Director del Trabajo Final
Usuario final	Personas y equipos técnicos que utilizan agentes de IA	-	Desarrolladores, analistas y perfiles de finanzas, RR. HH. e IT

A continuación se describen las principales características de cada interesado:

- **Responsable:** ejecuta la totalidad del trabajo técnico y la redacción de la memoria. Su disponibilidad es de tipo *part-time*, lo que condiciona el cronograma y obliga a planificar con holgura.
- **Orientador:** el Director del Trabajo Final es experto en la temática y colabora en la definición de los requerimientos, la metodología de evaluación y la revisión de la memoria.
- **Usuario final:** valora la privacidad (que sus datos no salgan de su equipo), un bajo impacto en la fluidez de uso (pocas falsas alarmas) y que la solución funcione en computadoras de capacidad modesta.

3. Propósito del proyecto

Evaluar y construir un sistema capaz de detectar, evaluar y controlar acciones maliciosas de agentes de inteligencia artificial antes de su ejecución. Se prioriza una ejecución liviana y local para preservar la privacidad del usuario siempre que sea posible, sin descartar otras alternativas, como el uso de la nube, según las capacidades del equipo. También se propone entregar evidencia reproducible sobre qué enfoques ofrecen el mejor equilibrio entre seguridad (detectar ataques), usabilidad (pocas falsas alarmas) y costo computacional (latencia, memoria y tamaño). Estos enfoques incluyen la detección de anomalías, los clasificadores entrenados, los modelos de decisión preentrenados y sus combinaciones. Además, se contemplarán versiones adaptadas a distintos niveles de recursos del equipo del usuario.

4. Alcance del proyecto

El proyecto incluye:

- Revisión del estado del arte y preparación de los datos: conjuntos públicos disponibles y de un conjunto sintético propio.
- Implementación de tres familias de detectores y de su combinación:
  - detección de anomalías: identifica lo que se aparta de lo normal sin requerir ejemplos de ataques
  - clasificadores entrenados: aprenden de ejemplos etiquetados a distinguir una acción riesgosa de una legítima
  - modelos de decisión preentrenados: modelos pequeños y rápidos que eligen entre opciones.
- Un banco de pruebas (*benchmark*) reproducible que mida, para cada enfoque: cuántos ataques detecta antes de ejecutarse, cuántas falsas alarmas genera (por acción y por sesión), la latencia, la memoria RAM, el tamaño del modelo y el uso de cómputo.
- Técnicas de optimización: cuantización (compresión) y comparación de versiones del mismo modelo en distintas precisiones, para hacerlo viable en equipos modestos.

- Un intermediario configurable (el *gate*) que se interpone entre el agente y sus herramientas, con una matriz de decisión que elige la mejor variante según el entorno (nube autorizada, GPU local, o poca memoria RAM, caso en el que se usa la versión liviana).
- La memoria del Trabajo Final, el código fuente documentado y los resultados reproducibles.

El proyecto no incluye:

- Un producto comercial listo para producción.
- El entrenamiento de modelos de lenguaje grandes desde cero; se parte de modelos existentes.
- La integración con un *sandbox* de agentes; esto quedaría como trabajo futuro o prueba exploratoria.
- La recolección de datos reales de usuarios; se trabaja con datos públicos y sintéticos, por lo que los resultados no se reportan como incidentes reales confirmados.

5. Supuestos del proyecto

Para el desarrollo del proyecto se supone que:

- Se dispone de conjuntos de datos públicos que pueden utilizarse como referencia para estudiar y evaluar técnicas de detección de comportamientos riesgosos en agentes de inteligencia artificial.
- Se dispone de acceso a modelos abiertos en repositorios como Hugging Face y GitHub.
- Se cuenta con acceso a cómputo con GPU de forma gratuita o de bajo costo (por ejemplo, Google Colab) para las partes que lo requieran; el resto corre en una computadora personal.
- La disponibilidad horaria de la responsable permite sostener las 600 h estimadas, distribuidas en el período de ejecución (modalidad *part-time*), con la orientación periódica del director.
- Las licencias de los modelos y conjuntos de datos de terceros permiten su uso con fines académicos y de investigación.
- La disponibilidad de los servicios de cómputo y el acceso a internet se mantienen razonablemente estables durante el proyecto.
- Los resultados se evalúan sobre datos sintéticos o de laboratorio; se asume que esto es suficiente para comparar enfoques entre sí, aunque no para afirmar su eficacia en un entorno de producción real.

6. Requerimientos

Los requerimientos se agrupan por afinidad.

1. Requerimientos funcionales:
   1.1. El sistema debe evaluar cada acción propuesta por el agente antes de ejecutarla y emitir una de tres decisiones: permitir, revisar o bloquear.
   1.2. El sistema debe usar como entrada únicamente información disponible antes de la acción (contexto de la sesión, herramienta, argumentos y permisos). No debe utilizar información posterior a la acción ni las etiquetas de referencia empleadas durante el entrenamiento o la evaluación.
   1.3. El sistema debe aplicar reglas de permisos verificables, independientes del modelo de IA (por ejemplo, denegar la lectura de archivos de credenciales).
   1.4. El sistema debe permitir intercambiar el mecanismo de evaluación del riesgo (detección de anomalías, clasificación o modelo preentrenado) sin modificar el resto de los componentes.
   1.5. El sistema debe soportar perfiles por usuario y por grupo de actividad, e identificar desviaciones respecto de los patrones de comportamiento habituales.
   1.6. El componente debe seleccionar automáticamente la variante del modelo de evaluación de riesgo en función de los recursos computacionales disponibles en el entorno de ejecución, que considere la capacidad de CPU, la disponibilidad de GPU y la posibilidad de utilizar servicios en la nube.
2. Requerimientos de desempeño:
   2.1. El sistema debe tomar cada decisión rápidamente; en la variante liviana ejecutada en CPU, el tiempo promedio entre la recepción de una solicitud y la emisión de una decisión no debe superar los 500 ms.
   2.2. El sistema debe poder funcionar usando como mucho 2 GB de memoria RAM adicional.
   2.3. El sistema debe ocupar como máximo 1 GB en disco.
3. Requerimientos de seguridad y privacidad:
   3.1. El sistema debe ofrecer un modo de funcionamiento en el que toda la inferencia se ejecute localmente, sin transmitir datos a servicios externos.
   3.2. El uso de la nube debe ser opcional y explícitamente autorizado por el usuario.
4. Requerimientos de documentación:
   4.1. Memoria del Trabajo Final.
   4.2. Documentación que permita reproducir los experimentos con los conjuntos de datos públicos.
   4.3. Documentación de los conjuntos de datos, con su origen y sus códigos de verificación de integridad (en inglés, *checksums*).
5. Requerimientos de testing:
   5.1. El proyecto debe incluir pruebas automatizadas del componente de control que verifiquen las decisiones de permitir, revisar y bloquear acciones, así como el cumplimiento de las reglas de permisos.
6. Requerimientos de interoperabilidad:

6.1. El sistema debe exponer su evaluación mediante una función que reciba el contexto de la sesión y la acción propuesta y devuelva la decisión: permitir, revisar o bloquear. La interfaz debe ser independiente del modelo de riesgo utilizado internamente, de modo que este pueda cambiarse sin alterar la forma de invocación.

7. Requerimientos regulatorios y de normas:

7.1. Cumplir con la normativa de protección de datos personales aplicable (en Argentina, la Ley 25.326; se consideran además principios del GDPR por buenas prácticas), dado que el sistema observa el comportamiento de los usuarios: minimización de datos, procesamiento local y anonimización cuando corresponda.

7.2. Respetar las licencias de los conjuntos de datos y modelos de terceros.

7. Historias de usuarios (*Product backlog*)

Las historias de usuario se derivan de los requerimientos (sección 6) y del alcance (sección 4). Se escriben desde la perspectiva de quienes desean cada capacidad: el usuario final (personas y equipos que delegan tareas en agentes de IA), el administrador de seguridad (quien configura reglas y perfiles), el desarrollador integrador (quien incorpora el *gate* a una plataforma anfitriona) y la responsable del Trabajo Final (en su rol de investigadora y de desarrolladora de la solución).

Criterio de ponderación. El tamaño de cada historia se expresa en *story points* y se calcula como la suma de tres factores, cada uno valorado en una escala de 1 a 5:

- **Complejidad:** cantidad de componentes del sistema involucrados y su grado de interacción.
- **Dificultad:** esfuerzo técnico y conocimiento necesarios para implementar la historia.
- **Incertidumbre:** desconocimiento inicial o riesgo de que los supuestos cambien durante el desarrollo.

De este modo, el puntaje mínimo posible es 3 y el máximo 15. Cuanto mayor es el valor, mayor es el tamaño relativo de la historia.

1. Como usuario final que delega tareas en un agente de IA,
quiero que cada acción propuesta se evalúe antes de ejecutarse y se clasifique en permitir, revisar o bloquear,
para evitar que una acción riesgosa provoque un daño difícil de revertir.

   Story points: 12 (complejidad: 5, dificultad: 4, incertidumbre: 3)
   Prioridad: alta

2. Como usuario final,
quiero que la decisión se tome usando únicamente información disponible antes de la acción (contexto de la sesión, herramienta, argumentos y permisos),
para asegurar que el sistema utiliza únicamente información disponible en el momento de tomar la decisión.

   Story points: 8 (complejidad: 2, dificultad: 3, incertidumbre: 3)
   Prioridad: alta

3. Como administrador de seguridad,
quiero definir reglas de permisos verificables e independientes del modelo de IA (por ejemplo, prohibir la lectura de archivos de credenciales),
para garantizar prohibiciones que el modelo no pueda anular.

   Story points: 6 (complejidad: 2, dificultad: 2, incertidumbre: 2)
   Prioridad: alta

4. Como investigadora,
quiero poder intercambiar el mecanismo de evaluación del riesgo (anomalías, clasificador o decisión preentrenada) sin modificar el resto del sistema,
para comparar los distintos enfoques en igualdad de condiciones.

   Story points: 8 (complejidad: 3, dificultad: 3, incertidumbre: 2)
   Prioridad: alta

5. Como administrador de seguridad,
quiero perfiles por usuario y por grupo de actividad que permitan identificar desviaciones respecto del patrón habitual,
para detectar comportamientos anómalos según el contexto de cada rol.

   Story points: 11 (complejidad: 3, dificultad: 4, incertidumbre: 4)
   Prioridad: media

6. Como usuario final con un equipo de recursos computacionales limitados,
quiero que el sistema elija automáticamente la variante de modelo según los recursos del entorno (nube, GPU o CPU con poca memoria RAM),
para usar la solución sin tener que configurarla manualmente.

   Story points: 8 (complejidad: 3, dificultad: 3, incertidumbre: 2)
   Prioridad: media

7. Como usuario final,
quiero que el sistema emita cada decisión en un tiempo promedio no superior a 500 ms cuando se ejecute la variante liviana sobre CPU,
para no entorpecer el flujo de trabajo del agente.

   Story points: 10 (complejidad: 2, dificultad: 4, incertidumbre: 4)
   Prioridad: media

8. Como usuario final,
quiero que la inferencia se ejecute de forma 100 % local sin enviar datos a internet, y que el uso de la nube sea opcional y explícitamente autorizado,
para preservar la privacidad de mi información.

   Story points: 6 (complejidad: 2, dificultad: 2, incertidumbre: 2)
   Prioridad: media

9. Como desarrollador integrador,
quiero una función que reciba el contexto de la sesión y la acción propuesta y devuelva la decisión,
para incorporar el *gate* al entorno que ejecuta al agente sin acoplarlo a una implementación particular.

   Story points: 5 (complejidad: 2, dificultad: 2, incertidumbre: 1)
   Prioridad: alta

10. Como investigadora,
quiero un banco de pruebas (*benchmark*) reproducible que mida, por enfoque, la tasa

de detección de ataque, las falsas alarmas, la latencia, la memoria RAM, el tamaño del modelo y el uso de cómputo,
para identificar el mejor equilibrio entre seguridad, usabilidad y costo.

Story points: 10 (complejidad: 4, dificultad: 3, incertidumbre: 3)
Prioridad: media

11. Como investigadora,
quiero construir un conjunto de datos con ejemplos públicos y sintéticos y criterios claros de permitir, revisar o bloquear,
para entrenar y evaluar los detectores sobre tareas legítimas, intentos de desvío y situaciones ambiguas.

    Story points: 13 (complejidad: 4, dificultad: 4, incertidumbre: 5)
    Prioridad: alta

12. Como investigadora,
quiero aplicar cuantización y comparar versiones del mismo modelo en distintas precisiones,
para hacerlo viable en equipos modestos sin perder demasiada capacidad de detección.

    Story points: 9 (complejidad: 3, dificultad: 3, incertidumbre: 3)
    Prioridad: baja

13. Como responsable del proyecto,
quiero pruebas automatizadas del *gate*,
para asegurar que las reglas y las decisiones se mantienen correctas frente a los cambios del sistema.

    Story points: 5 (complejidad: 2, dificultad: 2, incertidumbre: 1)
    Prioridad: baja

El total acumulado del *product backlog* es de 111 *story points*.

8. Entregables principales del proyecto

Los entregables principales del proyecto son:

- Memoria del Trabajo Final.
- Código fuente documentado del componente de control (el *gate*), el motor de reglas de permisos verificables y los detectores de riesgo.
- Implementación de las tres familias de detectores (anomalías, clasificadores entrenados y modelos de decisión preentrenados) y de su combinación.
- Conjunto de datos de evaluación, con datos públicos curados y ejemplos sintéticos, junto con su documentación, origen y códigos de verificación de integridad (en inglés, *checksums*).
- Banco de pruebas (*benchmark*) reproducible, con las métricas de detección, falsas alarmas, latencia, memoria, tamaño del modelo y uso de cómputo.
- Resultados experimentales reproducibles, con las tablas y figuras comparativas de los distintos enfoques.
- Documentación que permita reproducir los experimentos, con las instrucciones de instalación y ejecución.

9. Desglose del trabajo en tareas

Las tareas se agrupan por afinidad y se relacionan con los requerimientos definidos en la sección 6. La estimación se expresa en horas (h).

1. Gestión y organización del proyecto (38 h)
   - 1.1. Planificación del proyecto y elaboración del plan de GdP (24 h)
   - 1.2. Seguimiento del avance y reuniones de orientación con el director (14 h)
2. Relevamiento y estado del arte (56 h)
   - 2.1. Revisión de la literatura sobre *prompt injection* y seguridad en agentes (20 h)
   - 2.2. Estudio de modelos de protección existentes (Llama Guard, ShieldGemma, Granite Guardian, entre otros) (20 h)
   - 2.3. Estudio de mecanismos de control de herramientas y de detección de anomalías (16 h)
3. Conjunto de datos (84 h)
   - 3.1. Definición de criterios para distinguir acciones permitidas, a revisar y a bloquear (20 h)
   - 3.2. Recopilación y curación de conjuntos de datos públicos (24 h)
   - 3.3. Generación de ejemplos sintéticos (tareas legítimas, intentos de desvío y casos ambiguos) (24 h)

3.4. Documentación del conjunto de datos y cálculo de *checksums* (16 h)

4. Desarrollo de los detectores (122 h)
   4.1. Implementación del detector por anomalías (30 h)
   4.2. Implementación de los clasificadores entrenados (30 h)
   4.3. Integración de los modelos de decisión preentrenados (32 h)
   4.4. Combinación de los detectores (30 h)
5. Optimización y cuantización (46 h)
   5.1. Cuantización de los modelos (22 h)
   5.2. Comparación de versiones en distintas precisiones y su costo (24 h)
6. Intermediario (*gate*) e integración (66 h)
   6.1. Diseño e implementación del motor de reglas de permisos verificables (24 h)
   6.2. Implementación del *gate* y de su interfaz (contexto y acción a decisión) (22 h)
   6.3. Matriz de decisión y selección automática de la variante según los recursos (20 h)
7. Evaluación y banco de pruebas (66 h)
   7.1. Diseño del *benchmark* y de las métricas (20 h)
   7.2. Ejecución de los experimentos (26 h)
   7.3. Análisis de los resultados (20 h)
8. Pruebas automatizadas (18 h)
   8.1. Desarrollo de las pruebas automatizadas del *gate* (18 h)
9. Memoria del Trabajo Final (46 h)
   9.1. Redacción de la memoria (26 h)
   9.2. Revisión e incorporación de correcciones (20 h)
10. Presentación y cierre (18 h)
   10.1. Elaboración de la presentación (10 h)
   10.2. Ensayo de la presentación y cierre del proyecto (8 h)
11. Buffer para imprevistos (40 h)
   11.1. Tiempo reservado para retrasos, cambios de alcance y problemas técnicos (40 h)

Cantidad total de horas: 600 h.

10. Diagrama de Activity On Node

El diagrama de *Activity on Node* (figura 2) se construye a partir del desglose de tareas de la sección 9 y representa las dependencias entre las tareas del proyecto. Cada nodo corresponde a una tarea, identificada con su código del WBS, su nombre y su duración estimada; los tiempos están expresados en horas (h). El flujo avanza desde el hito de inicio (octubre de 2026) hasta el hito de fin (noviembre de 2027).

Los colores distinguen el rol de cada tarea en la red, según las referencias incluidas en el diagrama: en rojo las tareas del camino crítico, cuya demora afecta directamente la fecha de finalización del proyecto; en naranja las del camino semicrítico, con holgura reducida; en azul las tareas fuera del camino crítico, que cuentan con holgura; y en verde los hitos de inicio y fin.

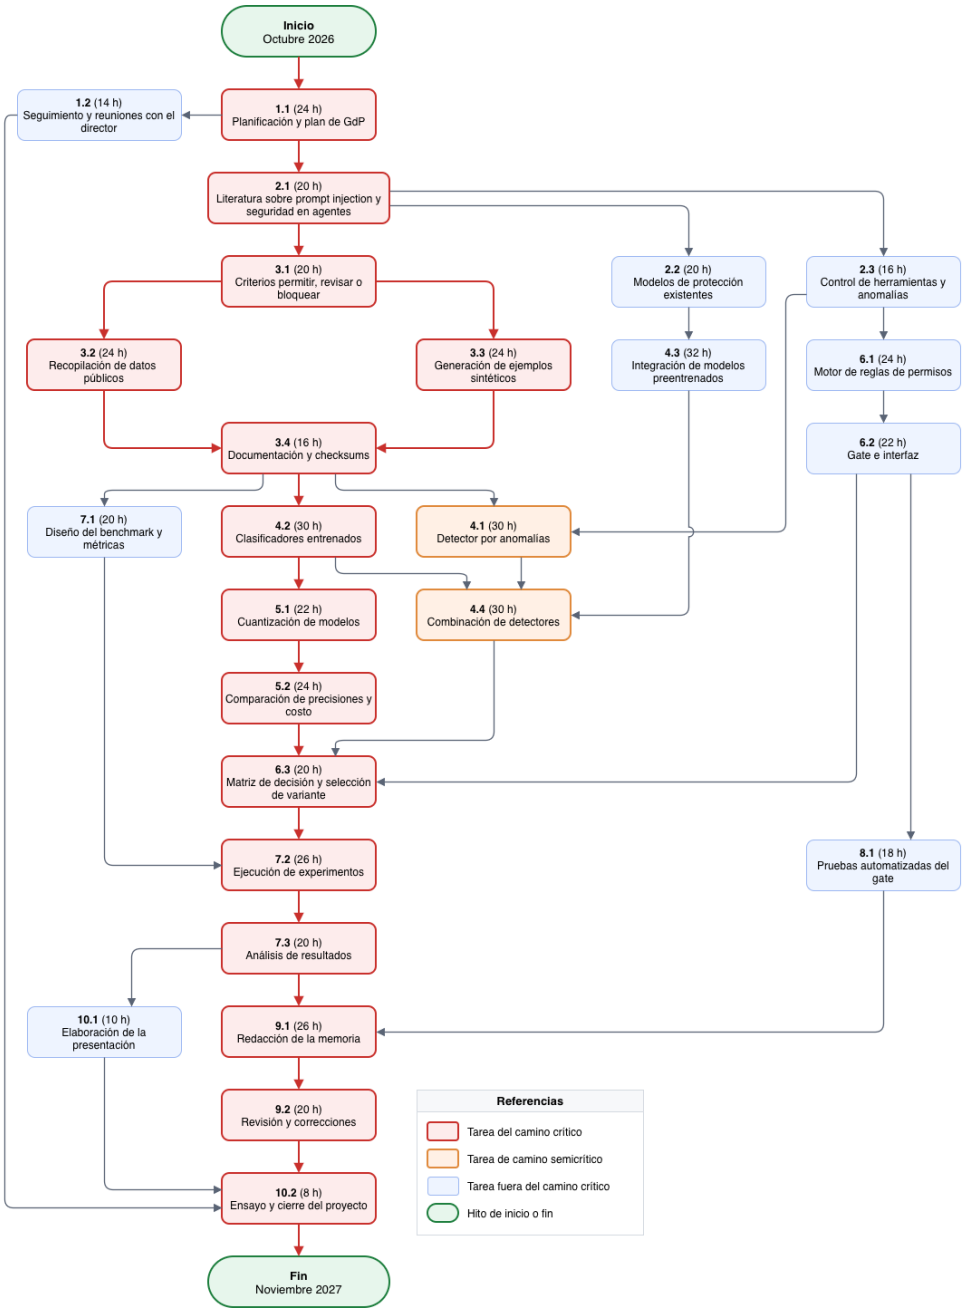


Figura 2. Diagrama de *Activity on Node*.

11. Diagrama de Gantt

Para la planificación temporal del proyecto se elaboró el diagrama de Gantt de la figura 3, construido a partir del desglose de tareas de la sección 9. Cada barra representa una tarea identificada con su código del WBS, su nombre y su duración estimada en horas; su posición y su longitud indican las fechas de inicio y de fin previstas.

El cronograma abarca desde el inicio del Trabajo Final, en octubre de 2026, hasta la presentación pública prevista para noviembre de 2027. Las tareas se ordenan respetando las dependencias reflejadas en el diagrama de *Activity on Node* de la sección 10; algunas se ejecutan en paralelo cuando las precedencias y los recursos lo permiten.

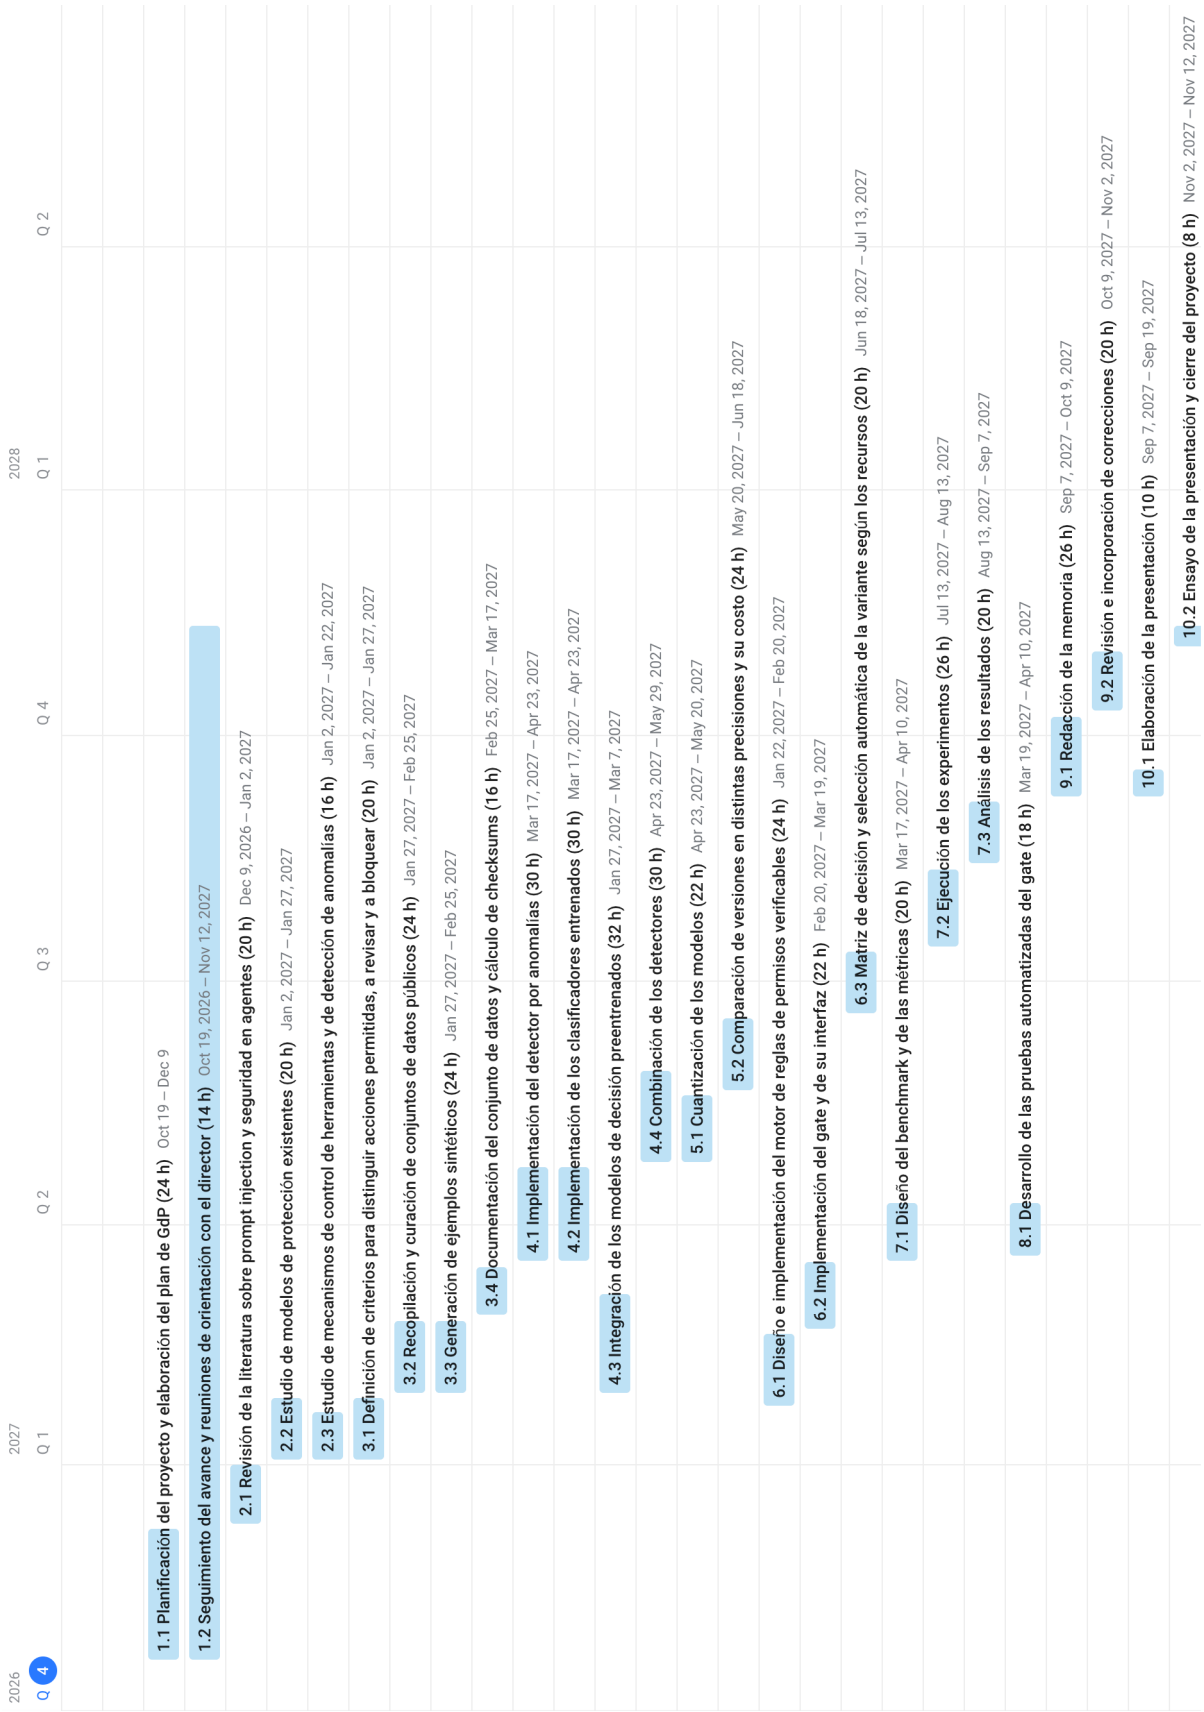


Figura 3. Diagrama de Gantt del proyecto.

12. Presupuesto detallado del proyecto

El presupuesto se expresa en dólares estadounidenses (USD). Dado el período de ejecución (desde octubre de 2026 hasta la defensa prevista en noviembre de 2027), se adopta el USD como moneda de referencia para evitar la distorsión que la inflación introduciría sobre valores expresados en pesos argentinos (ARS).

Al tratarse de un Trabajo Final académico e individual, el mayor componente del costo corresponde a la mano de obra de la responsable. Aunque no implica un desembolso monetario efectivo, se valoriza como costo de oportunidad a un valor hora de mercado de referencia para un perfil semi-senior de IA y datos en Argentina (USD 15/h), por lo que las 600 h estimadas constituyen el principal costo directo.

Los conjuntos de datos públicos, los modelos abiertos y el software utilizado son de uso gratuito, por lo que su costo directo es nulo; se incluyen de todos modos en la tabla para dejar constancia. El cómputo con GPU se cubre mediante una suscripción a Google Colab Pro durante los meses de experimentación. Entre los costos indirectos se consideran la amortización del equipo de cómputo personal, la energía eléctrica y la conexión a internet, imputados de forma proporcional al uso del proyecto.

Los supuestos de cálculo son:

- Valor hora de la responsable: USD 15/h (costo de oportunidad, ajustable).
- Google Colab Pro: USD 12 por mes durante 5 meses de experimentación (desarrollo de los detectores, optimización y evaluación).
- Amortización del equipo: notebook de USD 1.200, vida útil de 48 meses, con 13 meses de uso imputados al proyecto.
- Energía eléctrica e internet: imputación proporcional al uso durante el período de ejecución.

El detalle se presenta en la tabla 2.

Cuadro 2. Presupuesto detallado del proyecto (en USD).

COSTOS DIRECTOS			
Descripción	Cantidad	Valor unit. (USD)	Valor total (USD)
Mano de obra: gestión y organización del proyecto	38 h	15	570
Mano de obra: relevamiento y estado del arte	56 h	15	840
Mano de obra: conjunto de datos	84 h	15	1.260
Mano de obra: desarrollo de los detectores	122 h	15	1.830
Mano de obra: optimización y cuantización	46 h	15	690
Mano de obra: intermediario (*gate*) e integración	66 h	15	990
Mano de obra: evaluación y banco de pruebas	66 h	15	990
Mano de obra: pruebas automatizadas	18 h	15	270
Mano de obra: memoria del Trabajo Final	46 h	15	690
Mano de obra: presentación y cierre	18 h	15	270
Mano de obra: buffer para imprevistos	40 h	15	600
Suscripción a Google Colab Pro	5 meses	12	60
Conjuntos de datos públicos	—	0	0
Modelos abiertos y software de código abierto	—	0	0
		SUBTOTAL COSTOS DIRECTOS	9.060
COSTOS INDIRECTOS			
Descripción	Cantidad	Valor unit. (USD)	Valor total (USD)
Amortización del equipo de cómputo (notebook personal)	13 meses	25	325
Energía eléctrica (proporcional)	13 meses	—	45
Conexión a internet (proporcional)	13 meses	—	60
		SUBTOTAL COSTOS INDIRECTOS	430
		TOTAL	9.490

13. Gestión de riesgos

A continuación se identifican los principales riesgos del proyecto. Para cada uno se estima la severidad (S) y la probabilidad de ocurrencia (O) en una escala de 1 a 10, y se calcula el número de prioridad de riesgo como RPN = S × O. Los valores marcados con asterisco (*) corresponden a la situación luego de aplicar las medidas de mitigación.

Riesgo 1: no disponer de conjuntos de datos adecuados para caracterizar acciones maliciosas de agentes.

- Severidad (S): 9. Sin datos representativos no es posible entrenar ni evaluar los detectores, lo que compromete el núcleo del Trabajo Final.
- Ocurrencia (O): 6. Es un área reciente; existen conjuntos de *prompt injection*, pero no necesariamente con el etiquetado de permitir, revisar o bloquear que requiere el proyecto.

Riesgo 2: que la variante liviana no alcance las metas de desempeño (latencia y memoria) por el tamaño o el costo de los modelos.

- Severidad (S): 6. Afecta un requerimiento de desempeño, aunque el trabajo sigue siendo válido para comparar enfoques entre sí.
- Ocurrencia (O): 6. Los modelos de decisión pueden exceder los límites de RAM o de latencia en CPU sin optimización previa.

Riesgo 3: retrasos en el cronograma por la disponibilidad *part-time* de la responsable.

- Severidad (S): 5. Un desvío moderado puede comprimir las etapas finales, pero no impide completar el trabajo.
- Ocurrencia (O): 8. La modalidad *part-time* y la extensión del proyecto hacen que los desvíos sean probables.

Riesgo 4: pérdida o cambios en los límites de los servicios de cómputo gratuitos (por ejemplo, Google Colab).

- Severidad (S): 5. Obliga a reorganizar los experimentos que requieren GPU, con impacto acotado.
- Ocurrencia (O): 5. Los límites de estos servicios cambian con cierta frecuencia.

Riesgo 5: restricciones de licencias de modelos o conjuntos de datos de terceros que impidan su uso académico.

- Severidad (S): 6. Puede obligar a reemplazar un modelo o un conjunto de datos y rehacer parte del trabajo.
- Ocurrencia (O): 4. La mayoría de los modelos y datos previstos son abiertos y de uso académico permitido.

Riesgo	S	O	RPN	S*	O*	RPN*
1. Datos inadecuados o insuficientes	9	6	54	9	3	27
2. Metas de desempeño no alcanzadas	6	6	36	6	3	18
3. Retrasos por disponibilidad *part-time*	5	8	40	5	5	25
4. Límites de cómputo gratuito	5	5	25	5	5	25
5. Restricciones de licencias	6	4	24	6	4	24

Tabla de gestión de riesgos (el RPN se calcula como RPN = S × O):

Criterio adoptado: se elabora un plan de mitigación para los riesgos cuyo RPN sea mayor a 35. En consecuencia, se mitigan los riesgos 1, 2 y 3. Los valores marcados con asterisco (*) corresponden a la situación luego de aplicar la mitigación.

Plan de mitigación:

- Riesgo 1: construir un conjunto de datos sintético propio con criterios claros de etiquetado (previsto en el alcance), complementado con datos públicos parcialmente aplicables, y documentar su origen y sus *checksums*. Con esto la ocurrencia baja de 6 a 3 (S* = 9, O* = 3, RPN* = 27).
- Riesgo 2: aplicar cuantización y comparar versiones en distintas precisiones, y acotar las metas de latencia y memoria a la variante liviana sobre CPU. Con esto la ocurrencia baja de 6 a 3 (S* = 6, O* = 3, RPN* = 18).
- Riesgo 3: reservar un *buffer* de 40 h para imprevistos (sección 9), planificar con holgura y sostener el seguimiento periódico con el director. Con esto la ocurrencia baja de 8 a 5 (S* = 5, O* = 5, RPN* = 25).

Los riesgos 4 y 5 quedan por debajo del umbral y se monitorean sin un plan de mitigación específico.

14. Gestión de la calidad

Se seleccionan los diez requerimientos considerados más críticos para el valor del Trabajo Final. Para cada uno se indican las acciones de verificación (que consideran al entregable como "caja blanca", con conocimiento de su funcionamiento interno) y de validación (que lo consideran como "caja negra", contrastando el resultado contra los criterios acordados con el director). En este proyecto académico e individual, la validación se realiza con el director del Trabajo Final como referente de aceptación.

- Req 1.1 (funcional): evaluar cada acción y emitir una de tres decisiones (permitir, revisar o bloquear).
  - Verificación: pruebas automatizadas que recorran casos conocidos y comprueben que la salida siempre pertenece al conjunto de decisiones válidas y que la acción no se ejecuta antes de la evaluación.
  - Validación: revisión con el director de un conjunto de escenarios de ejemplo, confirmando que las decisiones emitidas son las esperadas.

- Req 1.2 (funcional): usar únicamente información disponible antes de la acción, sin información posterior ni etiquetas de referencia.
  - Verificación: inspección del código y de los *pipelines* de datos para confirmar que las etiquetas y las señales posteriores a la acción no se usan como entrada durante la inferencia.
  - Validación: contrastar los resultados con el director mediante una prueba de fuga de información, verificando que el desempeño no dependa de datos no disponibles en un uso real.
- Req 1.3 (funcional): aplicar reglas de permisos verificables, independientes del modelo de IA.
  - Verificación: pruebas unitarias sobre el motor de reglas que comprueben que una prohibición explícita nunca es anulada por la puntuación del modelo.
  - Validación: revisión con el director de un conjunto de reglas de ejemplo (por ejemplo, la lectura de archivos de credenciales) y su cumplimiento.
- Req 1.4 (funcional): intercambiar el mecanismo de evaluación del riesgo sin modificar el resto de los componentes.
  - Verificación: comprobar que las tres familias de detectores implementan la misma interfaz y se seleccionan por configuración, sin cambios en el resto del sistema.
  - Validación: demostrar al director el reemplazo de un detector por otro ejecutando el mismo caso con cada variante.
- Req 2.1 (desempeño): latencia promedio no superior a 500 ms en la variante liviana sobre CPU.
  - Verificación: medición automatizada de la latencia promedio sobre un lote de solicitudes en el entorno de referencia, registrando los resultados.
  - Validación: presentar al director el informe de latencia y confirmar que cumple el umbral acordado.
- Req 2.2 (desempeño): funcionar usando como mucho 2 GB de memoria RAM adicional.
  - Verificación: monitoreo del consumo de memoria durante la ejecución de la variante liviana y comparación contra el límite.
  - Validación: revisión con el director del reporte de uso de memoria en el equipo de referencia.
- Req 3.1 (seguridad y privacidad): ejecutar la inferencia de forma totalmente local, sin transmitir datos a servicios externos.
  - Verificación: análisis del tráfico de red durante la inferencia para confirmar que no hay envíos a servicios externos en el modo local.
  - Validación: demostración al director de una ejecución local completa, sin conexión a internet.
- Req 4.2 (documentación): permitir reproducir los experimentos con los conjuntos de datos públicos.
  - Verificación: ejecutar el procedimiento documentado en un entorno limpio y comprobar que los resultados coinciden con los reportados.

  - Validación: que el director reproduzca un experimento a partir de la documentación entregada y obtenga resultados equivalentes.

- Req 5.1 (testing): incluir pruebas automatizadas del componente de control.
  - Verificación: revisar la cobertura de las pruebas sobre las decisiones de permitir, revisar y bloquear y sobre el cumplimiento de las reglas de permisos.
  - Validación: ejecutar la batería de pruebas frente al director y confirmar que pasa en su totalidad.
- Req 6.1 (interoperabilidad): exponer la evaluación mediante una función independiente del modelo de riesgo interno.
  - Verificación: pruebas que invoquen la función con distintos modelos internos y comprueben que la firma y el formato de la decisión no cambian.
  - Validación: revisión con el director de la integración del *gate* en un caso de uso de ejemplo mediante esa función.

15. Procesos de cierre

Al finalizar el proyecto se realizará una reunión final de evaluación entre la responsable y el director del Trabajo Final, con el objetivo de cerrar formalmente el trabajo y dejar registro de las lecciones aprendidas. Las pautas para esa reunión son las siguientes.

- Análisis del cumplimiento del Plan de Proyecto original. La responsable preparará un informe de cierre que compare lo planificado con lo efectivamente ejecutado: horas reales frente a las estimadas por grupo de tareas, cumplimiento del cronograma (fechas de inicio y de fin) y uso del *buffer* para imprevistos. Ese informe se revisará junto con el director durante la reunión, identificando los desvíos y sus causas.
- Registro de técnicas, procedimientos y problemas. La responsable documentará, en un apartado de la memoria del Trabajo Final, qué técnicas y procedimientos resultaron útiles y cuáles no, los principales problemas que surgieron durante el desarrollo y cómo se resolvieron. Este registro servirá como referencia para trabajos futuros y quedará validado por el director.
- Agradecimientos. La responsable incluirá una sección de agradecimientos en la memoria, dirigida al director, a la cátedra y a quienes colaboraron u orientaron el trabajo. Al tratarse de un Trabajo Final académico e individual, no se prevé un acto ni gastos asociados: el reconocimiento se canaliza a través de esa sección y de la presentación pública.